

Chapter 4

数值线性代数

4.1 数值线性代数知识点总结

数值线性代数

S1. 矩阵代数基础

S1-1. 问题背景

- ① 傅里叶分析中的数值解
- ② 线性最小二乘问题

S1-2 Schur 分解和奇异值分解

- Schur 分解

引理 1. 对于复数向量 $x = (a_1, \dots, a_n)^T \in \mathbb{C}^n$, 若令

$$p = \begin{cases} \|x\|_2, & \text{若 } a_i = 0 \forall i \\ -e^{i \arg a_1} \|x\|_2, & \text{若 } a_1 \neq 0 \end{cases} \quad \text{其中 } \|x\|_2 = \sqrt{|a_1|^2 + \dots + |a_n|^2}$$

定义 : $H(\omega) = I - 2\omega \cdot w^*$, 其中 $\omega = \frac{x - pe}{\|x - pe\|_2}$, $H(\omega)$ 为 Hermitian 矩阵,
则有 $H(\omega)x = pe$.

定理 1: (Schur 分解定理)

设 $A \in \mathbb{C}^{n \times n}$, 则存在 $U \in \mathbb{C}^{n \times n}$, 使 $U^*AU = T$.

其中 T 为上三角矩阵, T 中对角元顺序依赖于 U 的选取,
其对角线元素为 A 的特征值.

讨论:

(1) A 是正规矩阵 ($AA^* = A^*A \Leftrightarrow \exists U \in \mathbb{C}^{n \times n}$, s.t.

$$U^*AU = \text{diag}(1, \dots, 1)$$

(2) A 是 Hermitian 矩阵的充分必要条件是存在 $U \in \mathbb{C}^{n \times n}$,
和实数角矩阵 Λ , s.t. $U^*AU = \Lambda$.

二、奇异值分解

定义: 设 $A \in \mathbb{C}^{m \times n}$, $A^* A$ 特征值的非负平方根称为 A 的奇异值, $A^* A$ 奇异值全体记作 $\sigma(A)$!

定理 2: (奇异值分解定理 (SVD))

设 $A \in \mathbb{C}_r^{m \times n}$, 则存在 $U \in \mathbb{C}^{m \times m}$ 和 $V \in \mathbb{C}^{n \times n}$, 使得:

$$U^* A V = \begin{bmatrix} \Sigma_r & 0 \\ 0 & 0 \end{bmatrix}_{m \times r},$$

其中 $\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$, $\sigma_1 \geq \dots \geq \sigma_r > 0$.

定义: Σ_r 在奇异数量: $v_i = V e_i$

Σ_r 在奇异数量: $u_i = U e_i$

结论: 设 $A \in \mathbb{C}_r^{m \times n}$, 则:

① $A^* A$ 的奇异值个数 = $\text{rank}(A) = r$.

② v_1, \dots, v_n 是 $\sqrt{\Sigma_r}$ 的一组特征向量.

③ u_1, \dots, u_r 是 $\sqrt{\Sigma_r}$ 的一组标准正交基

$$\text{④ } A = \sum_{i=1}^r \sigma_i u_i v_i^* = U \Sigma_r V^*$$

§1.3 向量范数和矩阵范数

一、向量范数

定义: \mathbb{C}^n 上的非负实值函数 $\| \cdot \|$, 对 $x, y \in \mathbb{C}^n$ 和 $\alpha \in \mathbb{C}$ 都有:

(1) 正定性: $x \neq 0 \Rightarrow \|x\| > 0$

(2) 平泛性: $\|\alpha x\| = |\alpha| \|x\|$

(3) 三角不等式: $\|x+y\| \leq \|x\| + \|y\|$

则称 $\| \cdot \|$ 为 \mathbb{C}^n 上的向量范数.

定义: ℓ_p 范数: $\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$
 $x = (x_1, \dots, x_n)^T \in \mathbb{C}^n, 1 \leq p \leq \infty$
 $(p=+\infty \text{时}, \|x\|_\infty = \max_{1 \leq i \leq n} |x_i|)$

Hölder 不等式: $\sum_{i=1}^n |x_i y_i| \leq \|x\|_p \|y\|_q, \frac{1}{p} + \frac{1}{q} = 1, p, q > 1.$

- 性质:
- (1) $1 \leq p \leq q, \|x\|_q \leq \|x\|_p, \forall x \in \mathbb{C}^n$
 - (2) $\lim_{p \rightarrow \infty} \|x\|_p = \|x\|_\infty, \forall x \in \mathbb{C}^n$.

定义: 设 $\|\cdot\|$ 是 \mathbb{C}^m 上的范数, $A \in \mathbb{C}_n^{m \times n}$ ($m \geq n$), 则由
 $\nu_A(x) = \|Ax\|, x \in \mathbb{C}^n$ 所以 ν_A 是 \mathbb{C}^n 上的非负实函数, ν_A 是 \mathbb{C}^n 上的范数.

定义: 设 $A \in \mathbb{C}^{n \times n}$ 为正定矩阵, 则由
 $\|x\|_A = \sqrt{x^* A x}, x \in \mathbb{C}^n$ 也称 $\|x\|_A$ 为 \mathbb{C}^n 上的范数.

性质3: 设 $\|\cdot\|$ 和 $\|\cdot\|_x$ 是 \mathbb{C}^n 上的任意两个范数, 则存在正数 S_1 和 S_2 , 使得对任意的 $x \in \mathbb{C}^n$ 都有:

$$S_1 \|x\| \leq \|x\|_x \leq S_2 \|x\|$$

即这两个范数等价.

(注: 等价的范数成立的条件是 \forall 为一个有限维空间.)

性质4: 设 $\|\cdot\|$ 是 \mathbb{C}^n 上的任意范数, 则

$$\lim_{k \rightarrow \infty} \|x^{(k)} - x^*\| = 0 \Leftrightarrow \lim_{k \rightarrow \infty} x_i^{(k)} = x_i^*, i = 1, 2, \dots, n.$$

二. 特征值范数(线性算子的范数)

定义: 若 $\|\cdot\|$ 在 $C^{n \times n}$ 上为一个非负定值函数 $\|A\|$ 对 $A, B, C \in C^{n \times n}$ 和 $\alpha \in \mathbb{C}$ 满足:

(1) 正定性: $A \neq 0 \Rightarrow \|A\| > 0$,

(2) 单位性: $\|\alpha A\| = |\alpha| \|A\|$

(3) 半可加性: $\|A+B\| \leq \|A\| + \|B\|$

(4) 相容性: $\|AB\| \leq \|A\| \cdot \|B\|$

则称 $\|\cdot\|$ 为 $C^{n \times n}$ 上的矩阵范数.

定义: Frobenius 范数: $\|A\|_F = \left(\sum_{i,j=1}^n |a_{ij}|^2 \right)^{\frac{1}{2}} = (\text{SVD}) \left(\sum_{i=1}^n \sigma_i^2 \right)^{\frac{1}{2}}$.

性质:

- $C^{n \times n}$ 上特征值范数等价

2) $\lim_{k \rightarrow \infty} \|A^{(k)} - A^{(\infty)}\| = 0 \Leftrightarrow \lim_{k \rightarrow \infty} \max_j |a_{ij}^{(k)} - a_{ij}^{(\infty)}| = 0$

定义: 诱导范数: 设 $\|\cdot\|$ 为 \mathbb{C}^n 上的范数, 则由 $\|A\| = \max_{\|x\|=1} \|Ax\|$,
 $A \in C^{n \times n}$ 所定义的范数 $\|\cdot\|$ 为 $C^{n \times n}$ 上由 $\|\cdot\|$ 诱导出的范数.

几种常见诱导范数:

$$(1) \|A\|_1 = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \quad (\text{列和范数})$$

$$(2) \|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \quad (\text{行和范数})$$

$$(3) \|A\|_2 = \sigma_1 \quad (\text{谱范数})$$

谱范数和性质：

$$(1) \quad \|A\|_2 = \max_{\|x\|_2=1} |y^* Ax| \quad \left. \begin{array}{l} \\ \end{array} \right\} SVD 分解$$

$$(2) \quad \|A^*\|_2 = \|A^\top\|_2 = \|A\|_2$$

$$(3) \quad \|A^* A\|_2 = \|A\|_2^2 = \|AA^*\|_2 \quad \text{谱导数} + SVD 分解$$

$$(4) \quad \|A\|_2^2 \leq \|A\|_1 \cdot \|A\|_\infty$$

$$(5) \quad \|UAV\|_2 = \|A\|_2, \quad \forall u, v \in \mathbb{C}^n$$

(Pf)

$$(A^* A z = \sigma_1^2 z, \quad 2|\sigma_1^2| |z|_1 = \|A^* A z\|_1 \leq \|A^*\|_1 \|A\|_1 \|z\|_1 = \|A\|_\infty \|A\|_1 \|z\|_1)$$

三、谱半径和矩阵序列的收敛性。

定义：谱半径： $\rho(A) = \max \{ |\lambda| : \lambda \in \lambda(A) \}$

性质：(1) $\rho(A) \leq \|A\|_1$. (任意范数)

(2) $\exists \forall \epsilon > 0$, 存在 $\mathbb{C}^{n \times n}$ 上的范数 $\|\cdot\|$ 使 $\|A\| = \rho(A) + \epsilon$.

定理 5. 若 $A \in \mathbb{C}^{n \times n}$, 则 $\lim_{k \rightarrow \infty} A^k = 0 \Leftrightarrow \rho(A) < 1$.

定理 6. 设 $A \in \mathbb{C}^{n \times n}$, 则有：

(1) $\sum_{k=0}^{\infty} A^k$ 收敛的充分必要条件是 $\rho(A) < 1$,

(2) 当 $\sum_{k=0}^{\infty} A^k$ 收敛时, 有 $\sum_{k=0}^{\infty} A^k = (I - A)^{-1}$, 且：

有 $\mathbb{C}^{n \times n}$ 上的算子范数 $\|\cdot\|$, 使：

$$\left\| (I - A)^{-1} - \sum_{k=0}^m A^k \right\| \leq \frac{\|A\|^{m+1}}{1 - \|A\|}, \quad \forall m \in \mathbb{Z}.$$

定理 7. 设 $A \in \mathbb{C}^{n \times n}$, $\|A\|_F$ 是 $\mathbb{C}^{n \times n}$ 上的范数, 则有

$$\text{证: } \lim_{k \rightarrow \infty} \|A^k\|^{\frac{1}{k}} = P(A).$$

§1.4. 正交投影和子空间之间的距离.

正交投影定义: 设 $X \subset \mathbb{C}^n$ 是一个子空间, 如果 $P \in \mathbb{C}^{n \times n}$, 满足
(1) $P^*P = P$, (2) $P^2 = P$, (3) $P^* = P$, 则称 P 是映射到 X 的正交投影, 称为 P_X .

定理 8. $\forall X \subset \mathbb{C}^n$ [一个子空间]. 在 $\mathbb{C}^{n \times n}$ 中存在一个映射到 X 的正交投影.

定义: 子空间之间的距离: $\text{dist}(X, Y) = \|P_X - P_Y\|_F$

定理 9. (C-S 分解定理)

设酉矩阵 Q 分块为 $Q = \begin{bmatrix} Q_{11} & Q_{12} \\ Q_{21} & Q_{22} \end{bmatrix}_{k \times j}$, $k \leq j$.

则存在酉矩阵 $U = \text{diag}(U_1, U_2)$, $V = \text{diag}(V_1, V_2)$,

$$\text{s.t. } U^* Q V = \begin{bmatrix} C & S & 0 \\ -S & C & 0 \\ 0 & 0 & I \end{bmatrix}_{k \times k \times j-k}$$

其中 $C = \text{diag}(C_1, \dots, C_k)$, $C_i = \cos \theta_i$, $S = \text{diag}(S_1, \dots, S_k)$,
 $S_i = \sin \theta_i$, $\frac{\pi}{2} \geq \theta_1 \geq \theta_2 \geq \dots \geq \theta_k \geq 0$.

定理 10. 设 $x = R(x_1)$, $y = R(y_1)$, 其中 $x_1, y_1 \in \mathbb{C}^{n \times k}$, $x_1^* x_1 = y_1^* y_1 = I_k$
证 $\text{dist}(x, y) = (\min_{i=1}^k |x_i^* y_i|)^{\frac{1}{2}}$, 其中 $\min_{i=1}^k |x_i^* y_i|$ 表示 $x_i^* y_i$ 的绝对值.

§1.5. 非负矩阵

定义: 设 $A = [a_{ij}] \in \mathbb{R}^{n \times n}$, 如果 $a_{ij} \geq 0$ (或 $a_{ij} > 0$). 则称 A 是非负 (或正) 矩阵, 记作 $A \geq 0$, (或 $A > 0$).

定理 11. (普半径的单调性)

设 $A \in \mathbb{C}^{n \times n}$, $B \in \mathbb{R}^{n \times n}$, 如果 $|A| \leq B$, 则 $\rho(A) \leq \rho(B)$.

定义: 设 $A \in \mathbb{R}^{n \times n}$, 若存在 n 阶排列矩阵 P . s.t.

$PAP^T = \begin{bmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{bmatrix}$, 其中 A_{11} 和 A_{22} 是两个低阶方阵.

则称 A 可分块 (可对角化), 否则称作不可分块.

定理 12. 设非负矩阵 $A \in \mathbb{R}^{n \times n}$, A 不可分块 ($\Rightarrow (I+A)^{-1} > 0$).

定理 13. (Perron-Frobenius 定理)

设非负矩阵 $A \in \mathbb{R}^{n \times n}$ 不可分块, 则:

(1) $\rho(A) > 0$, 而且是 A 的一个单特征值.

(2) $\exists x \in \mathbb{R}^n$, 且 $x > 0$, s.t. $Ax = \rho(A)x$

(3) 存在非负特征向量

定理 1. 设 $A \in \mathbb{R}^{n \times n}$ 是非负矩阵, $z \in \mathbb{R}^n$, $z > 0$, 如果 $\xi \in \mathbb{R}$, s.t. $Az > \xi z$, 则 $\rho(A) > \xi$.

定理 2. 设 $v_j \in \mathbb{C}$, $a_j \in \mathbb{R}$, $a_j > 0$, $j=1, 2, \dots, m$. 则

$$\left| \sum_{j=1}^m a_j v_j \right| \leq \sum_{j=1}^m |a_j| |v_j|$$

若 ξ 成立的充要条件是 $\exists y \in \mathbb{C}$, $|y|=1$, s.t. $yv_j \geq 0$, $j=1, 2, \dots, m$.

引理3. 设 $A = [a_{ij}] \in \mathbb{R}^{n \times n}$, 且 $A > 0$. 若 $u = (u_1, \dots, u_n)^T \in \mathbb{C}^n$, $u \neq 0$, 则有 $\lambda = p(A) > 0$.

$Au = \lambda u$, $|\lambda| = p(A)$, 且有 $\lambda = p(A) > 0$, $|u| > 0$ 且 $A|u| = p(A)|u|$ 满足.

证明: 设 $A \in \mathbb{R}^{n \times n}$, 且 $A > 0$, 且

(1) $p(A)$ 是 A 的特征值,

(2) $p(A)$ 的几何重数是 1, 相应的特征向量可以表示为正向量.

(3) 对于任意 $\lambda \in \sigma(A)$, 且 $\lambda \neq p(A)$, 必有 $|\lambda| < p(A)$.

引理4. 设 $A \in \mathbb{C}^{n \times n}$, $\lambda \in \sigma(A)$, 则 λ 是 A 的单特征值的充分必要条件是

1. 属于 λ 的特征向量只有一

(1) $\text{rank}(A - \lambda I) = n - 1$, 即 λ 的几何重数是 1.

(2) 属于 λ 的左特征向量 v 和 u 满足 $v^T u = 0$.

定理14. 设 A 是 n 阶非负不可分矩阵, λ 是 A 的模等于 $p(A)$ 的唯一同特征值.

则 λ 的特征向量个数为 $r = \text{rank}(A - \lambda I)$.

(1) A 的模为 $p(A)$ 的 r 个特征值为 $\lambda_j = p(A)e^{j\frac{2\pi i}{n}}$, $j=0, 1, \dots, n-1$.

(2) A 的特征多项式具有如下形式:

$$p(t) = t^n - t^{n-r} p(A)^r t^{n-r} - (t^{n-r} - \sum_{j=0}^{r-1} \delta_j t^j) p(A)^r,$$

其中 $r + m = n$, $\delta_j > 0$, $0 < |\delta_j| < 1$, $j=0, 1, \dots, r-1$.

定义: 双随机矩阵. 设 $A = [a_{ij}] \in \mathbb{R}^{n \times n}$, 如果 A 满足

$$a_{ij} \geq 0, \quad \sum_{i=1}^n a_{ij} = \sum_{j=1}^n a_{ij} = 1, \quad i, j = 1, 2, \dots, n$$

则称 A 为双随机矩阵.

性质: $p(A) = 1$, 且当 1-向量为 $e = (1, \dots, 1)^T$.

§1.6. 几个重要的定理.

定理 16. (Gershgorin 定理 — 圆盘定理)

设 $A = [a_{ij}] \in \mathbb{C}^{n \times n}$, 令

$$G_i(A) = \left\{ z \in \mathbb{C} : |z - a_{ii}| \leq \sum_{j \neq i} |a_{ij}| \right\}, \quad i=1, 2, \dots, n,$$

$$\text{证明} \quad (1) \pi(A) \subset \bigcup_{i=1}^n G_i(A)$$

(2) 如果上式所定的 n 个圆盘中, 有 m 个互相连通且与其余 $n-m$ 个不连通, 则在此 m 个圆盘 所成的连通区域中, 必有 A 的 m 个特征值.

定理 17. (Bauer-Fike 定理)

设 $A, B \in \mathbb{C}^{n \times n}$, 其中 A 为对角阵, 即 $A = Q^{-1} \Lambda Q$, Λ 为对角矩阵, 则对任意 $\mu \in \sigma(B)$, 必有 $\lambda \in \sigma(A)$. st

$$|\lambda - \mu| \leq \|Q^{-1}\|_2 \|Q\|_2 \|A - B\|_2.$$

引理: 设 $\bar{\lambda}_{k(n)}$ 的奇异值为 $\sigma_1 > \sigma_2 > \dots > \sigma_k > 0$, 则

$$\bar{\lambda}_k \geq \frac{|\lambda|^k}{(1+|\lambda|)^{k-1}}$$

定理 18. (由 Bauer-Fike 定理)

设 $A, B \in \mathbb{C}^{n \times n}$, 并假定 A 的 Jordan 分解为 $Q^{-1} J Q$, 其中 J 是 A 的 Jordan 标准形, 则对任意 $\mu \in \sigma(B)$,

$$\text{必有 } \lambda \in \sigma(A). \text{ st. } \frac{(\lambda - \mu)^m}{(1 + |\lambda - \mu|)^{m-1}} \leq \|Q(A - B)Q^{-1}\|_2$$

其中 m 是 J 中 λ 的最大 Jordan 块的阶数.

定理 19.

设 $A \in \mathbb{C}^{n \times n}$ 是埃尔米特阵 ($A^* A = AA^*$), 任取 $x \in \mathbb{C}^{n \times 1}$, $\|x\|_2 = 1$, 定义 $\mu(x) = x^* A x$, 则 $\min_{\lambda \in \sigma(A)} |\lambda - \mu(x)| \leq \| (A - \mu(x) I) x \|_2$

推论: 设 $A = [a_{ij}] \in \mathbb{C}^{n \times n}$ 是正规矩阵, 则

$$\mathcal{D}_i(A) = \left\{ z \in \mathbb{C} : |z - a_{ij}| \leq \left(\sum_{j \neq i} |a_{ij}|^2 \right)^{\frac{1}{2}} \right\}, \quad i=1, 2, \dots, n.$$

则每个圆盘 $\mathcal{D}_i(A)$ 中至少有一个特征值.

定理 20. (Hoffmann-Wielandt 定理)

设 A 和 B 是两个几阶正规矩阵, 它们的特征值是

$\lambda_1, \dots, \lambda_n$ 和 μ_1, \dots, μ_n , 则存在 $1, 2, \dots, n$ 为一个排列

$\pi(1), \dots, \pi(n)$, st.

$$\left(\sum_{i=1}^n |\mu_{\pi(i)} - \lambda_i|^2 \right)^{\frac{1}{2}} \leq \|B - A\|_F.$$

推论 6.2. $A, B \in \mathbb{C}^{n \times n}$ 是 Hermite 矩阵, 它们的特征值分别为:

$$\lambda_1 \geq \dots \geq \lambda_n \text{ 和 } \mu_1 \geq \dots \geq \mu_n.$$

$$\text{则有 } \left(\sum_{i=1}^n (\lambda_i - \mu_i)^2 \right)^{\frac{1}{2}} \leq \|B - A\|_F.$$

推论 6.3. 设 $A, B \in \mathbb{C}^{n \times n}$, 它们的特征值分别是

$$\sigma_1 \geq \dots \geq \sigma_n \geq 0, \text{ 和 } \tau_1 \geq \dots \geq \tau_n \geq 0.$$

$$\text{则有 } \left(\sum_{i=1}^n (\sigma_i - \tau_i)^2 \right)^{\frac{1}{2}} \leq \|B - A\|_F.$$

定理 21. (Courant-Fisher 和小极大原理)

设 $A \in \mathbb{C}^{n \times n}$ 为 Hermite 矩阵, 其特征值为 $\lambda_1 \geq \dots \geq \lambda_n$,

则有:

$$\lambda_i = \max_{\mathbf{G}_i^n} \min_{\mathbf{u} \in S(\mathbf{x})} \mathbf{u}^* A \mathbf{u} = \min_{\mathbf{G}_{n-i+1}^n} \max_{\mathbf{u} \in S(\mathbf{x})} \mathbf{u}^* A \mathbf{u}, \quad i=1, 2, \dots, n.$$

其中 \mathbf{G}_i^n 表示 \mathbb{C}^n 中所有该子空间的全体,

$$S(\mathbf{x}) = \{ \mathbf{u} \in X \mid \|\mathbf{u}\|_2 = 1 \}$$

定理 22. (B 扰动定理)

设 $A \in \mathbb{C}^{n \times n}$ 为 Hermite 矩阵, $B = U^* A U$, 其中 $U \in \mathbb{C}^{n \times n}$,
满足 $U^* U = I_{n-1}$. 再设 A 与 B 特征值分别为
 $\lambda_1 > \dots > \lambda_n$ 和 $\mu_1 > \dots > \mu_n$, 且 $\lambda_1 > \mu_1 > \lambda_2 > \mu_2 > \dots > \lambda_n$.

结论:

设 $A \in \mathbb{C}^{n \times n}$ 为 Hermite 矩阵, B 是 A 的一个 k 阶子阵
($1 \leq k \leq n-1$), 并设 A 与 B 特征值分别为 $\lambda_1 > \dots > \lambda_n$ 和 $\mu_1 > \dots > \mu_k$,
且 $\lambda_i > \mu_i > \lambda_{n-k+i}$, $i=1, 2, \dots, k$.

定理 23.

设 n 阶 Hermite 矩阵 A 与 B 特征值分别为 $\lambda_1 > \dots > \lambda_n$
和 $\mu_1 > \dots > \mu_n$, 并设 $E = B - A$ 的最大与最小特征值分
别是 E_1 和 E_n .

$$\text{且 } \lambda_i + E_n \leq \mu_i \leq \lambda_i + E_1, \quad i=1, 2, \dots, n.$$

定理 24.

(Weyl 定理)

在定理 23 的假设下, $|\mu_i - \lambda_i| \leq \|A - B\|_2$, $i=1, 2, \dots, n$.

§1.7 几种常用的变换

一、Householder 变换

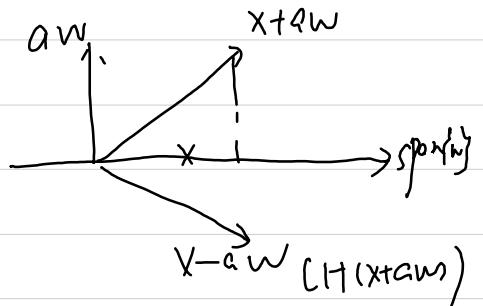
定义: $H = I - 2ww^T$, $w \in \mathbb{R}^n$, $\|w\|_2 = 1$

性质: H 是 Householder 变换:

(1) H 是实对称的正交矩阵

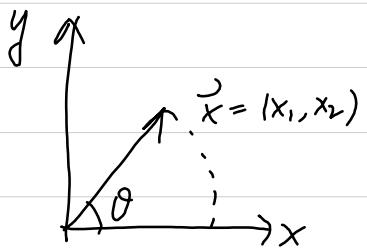
(2) $\pi(H) = \{-1, 1, 1, \dots, 1\}$, $Hw = -w$

(3) $\det(H) = -1$, (4) $Hx \in \text{span}\{w\}^\perp$ 且 $a \in \mathbb{R}$, $H(x+aw) = x-aw$.



二. Givens 变换 (平面旋转变换)

$$G(i, k, \theta) = \begin{bmatrix} 1 & & & \\ & \cos \theta & \sin \theta & \\ & -\sin \theta & \cos \theta & \\ & & & 1 \end{bmatrix}$$



算法 $x = (\xi_1, \dots, \xi_n)^T \xrightarrow{\text{Givens}} y = (\eta_1, \dots, \eta_n)^T$, 且 $\eta_k = 0$.

三. Gauss 变换

定义: Gauss 变换 L_K , 设 $x = (\xi_1, \dots, \xi_n)^T \in \mathbb{R}^n$, $\xi_k \neq 0$,

$$\sum c_{ik} = \frac{\xi_i}{\xi_k}, i=k+1, \dots, n.$$

并定义: $L_k = I - l_k e_k^T$, 其中 $l_k = (0, 0, \dots, 0, l_{k+1, k}, \dots, l_{n, k})^T$.

$$\text{则有 } L_k x = x - \xi_k l_k = (\xi_1, \dots, \xi_k, 0, 0, \dots, 0)^T,$$

即 L_k 为 Gauss 变换.

Section 2. 线性方程组的直接解法

§2.1. 矩阵的条件数

定义: 矩阵 A 的条件数 $K(A) = \|A\| \cdot \|A^{-1}\|$.

性质 2.1: 设 $A \in \mathbb{R}^{n \times n}$, A 非奇异, 则:

$$(1) K(A) \geq 1, K(A) = K(A^{-1}), K(A) = K(\alpha A), \alpha \neq 0.$$

$$(2) K_2(A) = \sigma_1(A) / \sigma_n(A)$$

$$(3) \text{若 } A \text{ 正规. } K_2(A) = \max_{\lambda \in \sigma(A)} |\lambda| / \min_{\lambda \in \sigma(A)} |\lambda|.$$

(4) A 是满秩阵, $K(A) = 1$

(5) $K_2(A) = K_2(UA) = K_2(AU)$, $\forall U \in \mathbb{R}^{n \times n}$.

定理: $K(A)$ 很大, 则 $Ax=b$ 病态或 A 病态, 反之为良态.

定理 22: 设 $A \in \mathbb{R}^{n \times n}$ 非奇异, $b \in \mathbb{R}^n$ 为非零向量, 再假定

$\delta A \in \mathbb{R}^{n \times n}$, 满足 $\|A^{-1}\| \|\delta A\| < 1$, 若 x 和 $x + \delta x$ 分别是

$Ax=b$ 和 $(A + \delta A)(x + \delta x) = b + \delta b$ 的解

$$\text{且 } \frac{\|\delta x\|}{\|x\|} \leq \frac{k}{1 - k \frac{\|\delta A\|}{\|A\|}} \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right), \text{ 其中 } k = K(A) = \|A\| \|A^{-1}\|.$$

§ 2.2. 基本解法回顾

一. Gauss 消去法

1. Gauss 换换和 LU 分解

(1) 利用 Gauss 换换求 A 的 LU 分解: $A = LU$, 其中 L 是单位下三角阵, U 是上三角阵.

(2) 求解 $Ly = b$, 得 y .

(3) 求解 $Ux = y$, 得 x .

2. 会选择元素的 Gauss 消去法.

(1) 求得对方阵 P 和 Q 和分解 $PAQ = LU$,

其中 U 是上三角阵, $L = [l_{ij}]$ 满足 $|l_{ij}| \leq 1$ 的单位下三角阵.

(2) 求解 $P^{-1}LUQ^{-1}x = b$ (分解成 4 个方程)

3. 部分选择元素的 Gauss 消去法:

只带取 $Q = I$, 即只在当前列中选取元素.

二. Cholesky 分解法 — 只适用于 A 为对称、不定矩阵.

(1) 求 Cholesky 分解: $A = G G^T$, 其中 G 为对角线元素都大于 0 的下三角矩阵.

(2) 求解 $Gy = b$

(3) 求解 $G^T x = y$

设 $G = [g_{ij}]$, 由 $a_{ij} = \sum_{k=1}^j g_{ik} g_{jk}$, $1 \leq j \leq n$. 逐列求出 g_{ij}

(本质是不选主元的 Gauss 消去法, 且计算量仅是 Gauss 法的一半)

三. LDL^T 分解 — 求解对称不定方程组的解法

对于对称不定的方程, Cholesky 分解: $A = G G^T$ 不一定成立, 考虑类似 Cholesky 分解的算法.

设 A 为一般的对称矩阵, 则 $A = LU$.

若 A 非奇异, A 的 LU 分解可以写成 $A = LDL^T$, 其中 D 是对角矩阵

可因为要保证对称性, 必须通过如下变换选取元: $PAP^T = LDL^T$.

尝试进行 LTL^T 分解, 其中 L 为下三角矩阵, T 为对称三对角阵.

四. Vandermonde 方程组的解法

Vandermonde 矩阵:

$$V = V(x_0, \dots, x_n) = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_0 & x_1 & \cdots & x_n \\ x_0^2 & x_1^2 & \cdots & x_n^2 \\ \vdots & \ddots & \ddots & \vdots \\ x_0^n & x_1^n & \cdots & x_n^n \end{bmatrix}_{(n+1) \times (n+1)}$$

五. Toeplitz 方程组的解法

1. Toeplitz 矩阵:

$$A = \begin{bmatrix} -r_0 & r_1 & \cdots & r_{n-1} \\ r_{-1} & r_0 & \cdots & r_{n-2} \\ r_{-2} & r_{-1} & \cdots & r_{n-3} \\ \vdots & \vdots & & \vdots \\ r_{-n} & r_{-n+1} & \cdots & r_1 \end{bmatrix} \in \mathbb{R}^{n \times n}$$

一. Yule-Walker 方程组:

$$T_n y = -(r_1, \dots, r_n)^T, \text{ 其中 } T_n = \begin{bmatrix} 1 & r_1 & \cdots & r_{n-1} \\ r_1 & 1 & \cdots & r_{n-2} \\ \cdots & \cdots & \cdots & \cdots \\ r_{n-1} & r_{n-2} & \cdots & 1 \end{bmatrix}$$

二. 一般右端项的 Toeplitz 方程组

$$T_n x = b, \quad b = (b_1, \dots, b_n)^T$$

上式可写为

三. Toeplitz 矩阵的逆

$$\text{设 } T_n^{-1} = \begin{bmatrix} T_{n-1} & E_{n-1} r_{n-1} \\ r_{n-1}^T E_{n-1} & 1 \end{bmatrix}^{-1} = \begin{bmatrix} x & v \\ v^T & \sigma \end{bmatrix}^{n-1},$$

第三章、线性方程组的迭代解法

§1. 迭代法概述

主要讨论单步常数迭代法，即：

$$x_k = G x_{k-1} + c, \quad k=1, 2, \dots$$

其中 $G \in \mathbb{R}^{n \times n}$ 称作迭代矩阵. x_0 称为初值.

定义：残差向量 $r_k = x_k - x_*$, 易见： $r_k = G^k r_0$.

定理1. 迭代法收敛的充分必要条件是 $P(G) < 1 \Leftrightarrow \lim_{k \rightarrow \infty} G^k = 0$.

定理2. 设 $\|G\|$ 是由向量范数 $\|\cdot\|_2$ 导出的算子范数.

如果 $\|G\| < 1$, 则迭代法 $x_k = Gx_{k-1} + c$ 收敛.

$$\text{且有: } \|x_k - x_*\|_2 \leq \frac{\|G\|^k}{1 - \|G\|} \cdot \|x_0 - x_*\|_2$$

$$\text{和: } \|x_k - x_*\|_2 \leq \frac{\|G\|}{1 - \|G\|} \|x_k - x_{k-1}\|_2$$

对一切自然数成立.

定义: 收敛速度: 假设 $r_k = x_k - x_*$, 则向量范数满足:

$$\|r_k\| \leq C \|r_{k-1}\|^\beta.$$

线性收敛: $\beta = 1$

超线性收敛: $\beta > 1$

二阶收敛: $\beta = 2$

在迭代法 $x_k = Gx_{k-1} + c$ 中, 我们可以得到: $\|r_k\| \leq \|G\|^k \|r_0\|$.

平均收敛速度定义为: $R_{AC}(G) = -\frac{1}{k} \ln \|G^k\|$.

渐近收敛速度定义为: $R(G) = \lim_{k \rightarrow \infty} R_k(G) = -\ln P(G)$

§ 2. 基本迭代法:

假定 A 有如下分块: $A = M - N$, 其中 M 为非奇异矩阵,

$\exists G = M^{-1}N$, $C = M^{-1}b$, 则此迭代法是相容的.

为了避免计算 M^{-1} , 将迭代法 $x_k = Gx_{k-1} + c$ 改为:

$$Mx_k = Nx_{k-1} + b, \quad k = 1, 2, \dots$$

下面给出基于矩阵分块的 4 种常用迭代法:

设 $A = \begin{bmatrix} A_{11} & A_{12} & \cdots & A_{1k} \\ A_{21} & A_{22} & \cdots & A_{2k} \\ \cdots & \cdots & \cdots & \cdots \\ A_{k1} & A_{k2} & \cdots & A_{kk} \end{bmatrix}$, 其对角块为易求解矩阵

$$\tilde{I} D = \text{diag}(A_{11}, A_{22}, \dots, A_{kk})$$

$$C_L = - \begin{bmatrix} 0 & 0 & \cdots & 0 & 0 \\ A_{21} & 0 & \cdots & 0 & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ A_{k1} & A_{k2} & \cdots & A_{kk-1} & 0 \end{bmatrix}$$

$$C_U = - \begin{bmatrix} 0 & A_{12} & \cdots & A_{1,k-1} & A_{1k} \\ 0 & 0 & \cdots & A_{2,k-1} & A_{2k} \\ \cdots & \cdots & \cdots & 0 & A_{k-1,k} \\ 0 & 0 & \cdots & 0 & 0 \end{bmatrix}$$

$$A = D - C_L - C_U = D(I - L - U)$$

($L = D^{-1}C_L$, $U = D^{-1}C_U$, 其中 L 为严格下三角, U 为严格上三角矩阵)

1. Jacobi 迭代

$$A = M_J - N_J, \text{ 其中 } M_J = D, N_J = C_L + C_U$$

$$\text{迭代矩阵为 } J = M_J^{-1}N_J = D^{-1}(C_L + C_U) = L + U = I - D^{-1}A$$

$$\text{迭代格式为: } Dx_m = (C_L + C_U)x_{m-1} + b, m=1, 2, \dots$$

2. Gauss-Seidel 迭代法

$$A = M_G - N_G, \text{ 其中 } M_G = D - C_L, N_G = C_U$$

$$\text{迭代矩阵为: } G = (D - C_L)^{-1}C_U = (I - L)^{-1}U$$

$$\text{迭代格式为: } (D - C_L)x_m = C_Ux_{m-1} + b$$

3. 超松弛迭代法 (SOR)

$$A = M_W - N_W, \text{ 其中 } M_W = \frac{1-w}{w}D - C_L, N_W = \frac{1-w}{w}D + C_U$$

$w \neq 0, w \in \mathbb{R}^+$, 称为松弛因子.

$$\text{迭代矩阵为: } B_W = M_W^{-1}N_W = (I - wL)^{-1}(wU + (1-w)I)$$

逐行迭代法: $(D - wC_L)x_m = (wC_U + (1-w)D)x_{m-1} + wb$,
 $m=1, 2, \dots$ (两边同乘 w , 通常 w 很小)

4. 对称超松弛法 (SSOR)

$$A = M_S - N_S$$

其中 $M_S = \frac{1}{w(2-w)} \left\{ D - w(C_L + C_U) + w^2 C_L D^{-1} C_U \right\}$

$$= \frac{1}{w(2-w)} (D - wC_L)^{-1} D^{-1} (D - wC_U).$$

$$N_S = \frac{1}{w(2-w)} \left\{ (1-w)^2 D + w(1+w)(C_L + C_U) + w^2 C_L D^{-1} C_U \right\}$$

$$= \frac{1}{w(2-w)} [(rw)D + wC_L] D^{-1} [(1-w)D + wC_U].$$

§3. 对称矩阵和某些迭代法的收敛性

引理 3.1 设 $A \in \mathbb{C}^{n \times n}$ 是 Hermite 矩阵, 且 A 分解为 $A = M - N$, 其中 M 为非奇异矩阵, 则 $M^* + N$ 是 Hermite 矩阵, 且由任意 $\text{Tr } x \in \mathbb{C}^n$, 有:

$$x^* A x - \tilde{x}^* A \tilde{x} = u^* (M^* + N) u, \text{ 其中 } \tilde{x} = M^{-1} N x, u = x - \tilde{x}.$$

定理 3.1 假设条件同引理 3.1, 则:

- (1) A 和 $M^* + N$ 正定 $\Leftrightarrow \rho(M^{-1} N) < 1$
(2) $\rho(M^{-1} N) < 1$ 和 $M^* + N$ 正定 $\Rightarrow A$ 正定

定理 3.2 假设讨论的矩阵 A 是对称正定的, 则:

(1) 当 $D - A$ 正定时, Jacobi 迭代法收敛.

(2) 当 $0 < w < 2$, SOR 和 SSOR 迭代法收敛.

定理 3.3 假设讨论的矩阵 A 是对称非正定的. 则

(1) 当 $D - A$ 正定时, Jacobi 迭代法收敛.

(2) 当 $0 < \omega < 2 \lambda_2$, SOR 和 SSOR 迭代法收敛.

定理 3.3. 设上节讨论的矩阵 A 是实对称的, 则

(1) 当 $D-A$ 正定且 Jacobi 迭代法收敛时, A 正定.

(2) 当 D 正定, 且存在 $\omega \in (0, 2)$ 使得 SOR 和 SSOR 迭代法收敛时, A 正定.

§4. H 矩阵和某些迭代法的收敛性

定义: M 矩阵: 设 $A = [a_{ij}] \in \mathbb{R}^{n \times n}$, 若 A 可表示成 $A = SI - B$, 其中 $B \geq 0$, 则当 $S > P(B)$ 时, A 为非奇异的 M 矩阵, 简称 M 矩阵.

若 A 既是: $a_{ij} \leq 0$, $1 \leq i \neq j \leq n$, $a_{ii} > 0$, $i=1, 2, \dots, n$.
称 A 为 L 矩阵.

定理 4.1 $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ 是 M 矩阵的充分必要条件是 A 是 L 矩阵.
且 $A^{-1} \geq 0$.

定义: 称半正定矩阵 $m(A)$, 设 $A \in \mathbb{C}^{n \times n}$, $m(A)$ 是非奇异 M 矩阵,
则 A 为非奇异 H 矩阵. (弱) 半格对角占优矩阵, 设
 $A \in \mathbb{C}^{n \times n}$, 满足

$$|a_{ii}| \geq \sum_{j \neq i} |a_{ij}|, \quad i=1, 2, \dots, n.$$

定理 4.1. 半格对角占优矩阵或不可分的弱半格对角占优矩阵
是非奇异矩阵.

定理 4.2. 半格对角占优或不可分的弱半格对角占优矩阵是 H 矩阵.

迭代法 Part II.

引理 4.2. 设 $M = [w_{ij}] \in \mathbb{C}^{n \times n}$ 是严格对角占优的,

且 $\eta_{ij} \neq 0$. 则 $N = [\eta_{ij}] \in \mathbb{C}^{n \times n}$, 有:

$$\|M^{-1}N\|_\infty \leq \max_{1 \leq i \leq n} \frac{\sum_{j=1}^n |\eta_{ij}|}{|w_{ii}| - \sum_{j \neq i} |w_{ij}|}$$

引理 4.3. 设 $M = [w_{ij}] \in \mathbb{C}^{n \times n}$ 是严格对角占优的 L 矩阵,

$N = [\eta_{ij}] \in \mathbb{R}^{n \times n}$ 是非负的,

且

$$\rho(M^{-1}N) \geq \min_{1 \leq i \leq n} \frac{\sum_{j=1}^n |\eta_{ij}|}{|w_{ii}| - \sum_{j \neq i} |w_{ij}|}$$

* AOR 和 SAOR 迭代法.

D, C_L, C_U 分别定义同 SOR, SSOR, $A = D - C_L - C_U$.

AOR 迭代矩阵定义为: (快速松弛法迭代矩阵)

$$G_{AOR} = (D - rC_L)^{-1} [(1-w)D + (w-r)C_L + wC_U]$$

其中 r, w 为松弛参数.

引理 4.3. 设 $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ 满足 $a_{ii} \neq 0, i=1, \dots, n$, 则 A 是 H 矩阵
等价于 $\rho(IJ) < 1$, 其中 J 表示 A 的 Jacobi 迭代矩阵.

引理 4.4. 设 $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ 满足 $a_{ii} \neq 0, i=1, \dots, n, 0 \leq r \leq w$,
且 J, SJ 为非奇异的:

(1) A 是 H 矩阵

(2) 存在 $\sigma \in \sigma(A)$ 和 $w \in [0, \frac{2}{1 + \rho(J)}]$, 有 $\rho(G_{AOR}) < 1$,

(3) 存在 $\sigma \in \sigma(A)$ 和 $w \in [0, \frac{2}{1 + \rho(J)}]$, 有 $\rho(G_{SAOR}) < 1$

习题 4.1. 如果 A 是严格对角占优矩阵或不可分离严格对角占优矩阵， $0 \leq w < 2/(c_1 + p(j))$ ，则对应的 Jacobi 点，Gauss-Seidel，及 SOR 和 SSOR 迭代法都是收敛的。

§5. 逐次逼近加速

第四章 艾伦堡梯度法

§1. 最速下降法

定义： $\varphi(x) = \frac{1}{2}x^T Ax - b^T x$. 则 $\nabla \varphi(x) = Ax - b$, A 为 φ 的 Hessian 矩阵.

若 A 为对称正定矩阵，则 $\varphi(x)$ 有唯一极小点 x_* , 且 $Ax_* = b \Leftrightarrow \varphi(x_*) = \min_x \varphi(x)$.

习题 1.1 设 A 为特征值为 $0 < \lambda_1 \leq \dots \leq \lambda_n$. 则最速下降法产生向量

$\{x_k\}_{k=0}^{w_0}$ 满足

$$\|x_k - x_*\|_A \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^k \|x_0 - x_*\|_A$$

其中 $x_* = A^{-1}b$, $\|\cdot\|_A = \sqrt{x^T A x}$.

习题 1.1. 设 A 的特征值为 $0 < \lambda_1 \leq \dots \leq \lambda_n$, $P(t)$ 是一个多项式

$$\|P(A)x\|_A \leq \max_{1 \leq i \leq n} |p(\lambda_i)| \|x\|_A, \quad \forall x \in \mathbb{R}^n.$$

§2. 一致凸函数的性质

定义：互相关 A 艾伦堡， $P^T A q = 0$

定义： k 维超平面，设 p_1, \dots, p_{n-k} 线性无关， $s_1, \dots, s_{n-k} \in \mathbb{R}$ ，
则 $H, \Pi_k = \{x \in \mathbb{R}^n \mid p_i^T x = s_i, i=1, \dots, n-k\}$ 为 k 维超平面。

12. ① $\Pi_k \subset \mathbb{R}^n$, 一般不是 \mathbb{R}^n 中的子空间, 当 $\delta_1 = \dots = \delta_{n-k} = 0$ 时, 是 \mathbb{R}^n 的 k 维子空间.
- ② Π_k 是 $Bx = b$ 的解集, 其中 $B = [P_1, \dots, P_{n-k}]^T$, $b = (\delta_1, \dots, \delta_{n-k})^T$.
- ③ P_i 称为 Π_k 的法向量.
- ④ 设 $u_1, \dots, u_k \in \text{Ker } B$, 对 $x_0 \in \Pi_k$, 对 $x \in \Pi_k$, 有:
- $$x = x_0 + a_1 u_1 + \dots + a_k u_k, \text{ 其中 } a_i \in \mathbb{R}.$$
- $\therefore \Pi_k = \{x = x_0 + \sum y_j u_j \mid y_j \in \mathbb{R}\}, \quad U = [u_1, \dots, u_k].$
- ⑤ 向量 p 在 Π_k 中 $\Leftrightarrow p$ 从 x_0 起点和终点都在 Π_k 中
 \Leftrightarrow 起点在 Π_k 中, 且 $p_i^T p = 0, i=1, \dots, n-k$.
 实际上, $p = \beta_1 u_1 + \dots + \beta_k u_k, p \in \text{Ker } B$.
- ⑥ $q \perp \Pi_k \Leftrightarrow q^T u_i = 0, \text{ 其中 } U = [u_1, \dots, u_k].$

13. 考虑 $\hat{\Pi}_{n-k}$, 设 Π_k 是 U, P_1, \dots, P_{n-k} 为法向量的 k 维子空间. 则 $\hat{\Pi}_{n-k} := x_* + a_1 A^{-1} P_1 + \dots + a_{n-k} A^{-1} P_{n-k}$ 为 Π_k 的共轭子空间, 其中 $x_* = A^{-1} b$.

14. ① $\forall p \in \Pi_k, q \in \hat{\Pi}_k, p \in \text{Ker } [P_1, \dots, P_{n-k}], q \in \text{span}\{A^{-1} P_1, \dots, A^{-1} P_{n-k}\}$
 $\therefore q^T A p = 0,$
- ② 若 $\Pi_k = x_0 + a_1 u_1 + \dots + a_k u_k, \text{ 且 } A u_1, \dots, A u_k \notin \hat{\Pi}_k$ 为法向量.

15. $m-1$ 维共轭子空间 $E_m := \{x \in \mathbb{R}^n \mid (x-x_0)^T B(x-x_0) = r\}$, 其中 B 为 $n \times n$ 的矩阵, x_0 称为共轭子空间中心.
 例: $E_{n-1} : \psi(x) = r, (r > \psi(x_0))$ 是 $U, x_* = A^{-1} b$ 为法向量的 $n-1$ 维共轭子空间.

$$\psi(x) = \frac{1}{2} x^T A x - b^T x = \frac{1}{2} x^T A x - x_*^T A x = \frac{1}{2} (x-x_*)^T A (x-x_*) - \frac{1}{2} x_*^T A x_* = r.$$

定理 2.1. 设 $\Pi_k: x = x_0 + Uy$, $y \in \mathbb{R}^k$ 是一个 k 维超平面, 其中 $U \in \mathbb{R}_k^{n \times k}$, 且:

- (1) y 在 Π_k 上的极小点是 $-\tau_k$.
- (2) y 在 Π_k 上的极小点正好是 Π_k 在 $n-1$ 维超平面的中心 E_{n-1} : $\psi(x) \Rightarrow$ 所得的 $n-1$ 维超平面的中心,

$E_{n-1} = E_m \cap \Pi_k$, 所界定的超平面的中心

- (3) \tilde{x} 是 ψ 在 Π_k 上的极小点, 充分必要条件是 ψ 在 \tilde{x} 的梯度 $\nabla \psi(\tilde{x})$, 垂直于 Π_k .

定理 2.2 设 p_1, \dots, p_{n-k} 是 $n-k$ 个线性无关的向量, 则 ψ 在任一以 p_1, \dots, p_{n-k} 为法向量 k 维超平面 Π_k 上的极小点必位于某些 k 维超平面 Π_{n-k} 上.

§3. 艾克斯梯度法

假设 p_k 是地位梯度方向更好的方向, 则最速下降法可改善为:

$$x_{k+1} = x_k + \alpha_{k+1} p_k.$$

$$\text{其中 } \alpha_{k+1} = r_k^T p_k / p_k^T A p_k, \quad r_k = b - Ax_k.$$

定理 3. 设 $m < n$, $1 \leq k \leq m$, 有

$$(1) \quad p_i^T r_k = 0, \quad i=0, 1, \dots, k-1$$

$$(2) \quad r_i^T r_k = 0, \quad i=0, 1, \dots, k-1$$

$$(3) \quad p_i^T A p_k = 0, \quad i=0, 1, \dots, k-1$$

$$(4) \quad \text{span}\{r_0, r_1, \dots, r_k\} = \text{span}\{p_0, p_1, \dots, p_k\} = \text{span}\{r_0, Ar_0, \dots, A^k r_0\}$$

定义：Krylov子空间， $K(A, r_0, j) = \text{span}\{r_0, Ar_0, \dots, A^{j-1}r_0\}$

定理3.2：设CG算法执行到 $k=m$ 时结束，则对于 $\forall k, 1 \leq k \leq m$ ，有：

- (1) x_k 是 ψ 在 k 维超平面 Π_k : $x = x_0 + \sum_{i=0}^k p_i e_i$ 上的极小点。
- (2) p_k 与 ψ 在 x_k 的负梯度方向 $r_k = b - Ax_k$ 在 Π_k 上的投影同向。

§4. 实用共轭梯度法和收敛性。

(令误差向量 $u_k = x_k - x_\star$)

引理4.1： $\|u_k\|_A \leq \min_{g_k \in \mathcal{G}_k^{(10)}} \max_{\lambda \in \lambda(A)} |g_k(\lambda)| \|u_0\|_A$.

其中 $g_k^{(10)}$ 表示满足 $g_k^{(10)} = g_k$ 且次数不超过 k 的实系数多项式。

定理4.1：在引理4.1的假设下，有：

$$\|u_k\|_A \leq 2 \left(\frac{\sqrt{k}-1}{\sqrt{k}+1} \right)^k \|u_0\|_A, \text{ 其中 } k = k_2(A).$$

定理4.2：

§5. 强迫共轭梯度法 (PCG)

选取正交矩阵 C , 令 $\tilde{A} = C^{-1}AC^{-T}$,

假设 \tilde{A} 的特征值分布在一个较小区间 (或 $R(\tilde{A})$ 较小)

再应用共轭梯度法求解 $A\tilde{x} = \tilde{b}$, 其中 $\tilde{x} = C^T x$, $\tilde{b} = C^T b$.

最优矩阵 M 应该满足如下条件:

- (1) M 对称正定, $M = C C^T$, C 可逆
- (2) M 应该与 A 的稀疏性差不多
- (3) $M^{-1} A$ (即 $\tilde{A} = C^{-1} A C^{-1}$) 的特征值分布集中.
- (4) $M^{-1} r$ 的方程组容易求解

§6. 不完全分解处理方法

6.1. 松弛不完全 LU 分解

定义: 松弛不完全 LU 分解 (PILU) 分解为:

$$A = L U + R.$$

定义: 对角占优矩阵. $A = [a_{ij}] \in \mathbb{R}^{n \times n}$, 且 $|a_{ii}| > \sum_{j \neq i} |a_{ij}|, i=1, 2, \dots, n$.

定义: M 矩阵. $A = [a_{ij}] \in \mathbb{R}^{n \times n}$. 满足:

- (1) $a_{ii} > 0, i=1, 2, \dots, n-1, a_{nn} \geq 0$
- (2) $a_{ij} \leq 0, i \neq j$.
- (3) $n(i) \geq i, i=1, 2, \dots, n-1$, 其中 $n(i) = \max\{j : 1 \leq j \leq n, a_{ij} \neq 0\}$

定理 6-1. 设 $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ 是对角占优的 M 矩阵, 则松弛不完全 LU 分解产生的矩阵 A_1, A_2, \dots, A_n 都是对角占优的介矩阵, 而且有:

$$(1) a_{ij}^{(k+1)} \leq a_{ij}^{(k)} \leq 0, k+1 \leq i+j \leq n,$$

$$(2) \quad S_i^{(k+1)} \geq S_i^{(k)} \geq 0, \quad i=k+1, \dots, n$$

$$(3) \quad 0 < a_{ii}^{(k+1)} \leq a_{ii}^{(k)}, \quad i=k+1$$

$$(4) \quad 0 \leq a_{nn}^{(k+1)} \leq a_{nn}^{(k)}$$

其中 $S_i^{(k)}$ 表示 A_k 的第 i 行元素之和, $S_i^{(k)} = \sum_{j=1}^n a_{ij}^{(k)}$.

推论 6.1: 设 $A \in \mathbb{R}^{n \times n}$ 是对角占优的矩阵, 则对任意的指标集 $\mathcal{Q}_f (f_n \supset f \supset \mathcal{Q}_A)$ 和任意的参数 $w (0 \leq w \leq 1)$, 都存在 A 关于 f 和 w 的松弛不完全 LU 分解.

6.2 松弛不完全 Cholesky 分解

$$\text{设 } A = \begin{bmatrix} D_1 & A_1^T & 0 \\ A_1 & D_2 & \ddots & A_2^T \\ \vdots & \ddots & \ddots & \ddots & A_m^T \\ 0 & \cdots & A_m & D_m \end{bmatrix} \in \mathbb{R}^{n \times n} \text{ 是块三对角矩阵, 其中 } D_k$$

是 $m_k \times m_k$ 的三对角矩阵.

考虑关于 \mathcal{Q}_f 和 w 的松弛不完全 Cholesky 分解 (RIC):

$$A = L D L^T + R$$

其中 $R = [r_{ij}]$, $r_{ij} = 0, (i, j) \notin \mathcal{Q}_f$, $r_{ii} = -w \sum_{j \neq i} r_{ij}, i=1, 2, \dots, n$.

D 为对角矩阵, 易知 R 也为对角矩阵.

RIC 的实现类似于 RLU

LDL^T 矩阵的稳定性由如下定理保证:

定理 6.2: 设 $A \in \mathbb{R}^{n \times n}$ 是对称半正定对角占优的矩阵,

则对任意的对称指标集 \mathcal{Q}_f , $f_n \supset f \supset \mathcal{Q}_A$ 和任意的松弛参数 $w, 0 \leq w \leq 1$, A 都有关于 \mathcal{Q}_f 和 w 的松弛不完全 Cholesky 分解, $A = L D L^T + R$, 且 $L D L^T$ 都是对称稳定的, 即 D 的每个对角元

都是云密.

第二章：大型稀疏线性方程组求解

§1. Krylov 子空间方法

一. CG, PCG

$\text{定理}:$ $\text{span}\{v, Av, \dots, A^{m-1}v\} = K_m(A, v), v \neq 0.$

Krylov 子空间性质

二. Arnoldi 方法 (飞升方法) (类似于 Schmidt 正交化)

三. 广义最小余量法 (GMRES)

1. 基本 GMRES 方法

设 $K_m = \text{span}\{v_1, Av_1, \dots, A^{m-1}v_1\}$, 设 v_1, \dots, v_m 是一组正交飞升基, 令 $V_m = [v_1, \dots, v_m]$

则 $\forall x \in x_0 + K_m, x = x_0 + V_m y.$

$$\text{定理: } J(y) = \|b - Ax\|_2 = \|b - A(x_0 + V_m y)\|_2,$$

$$\text{可计算得: } J(y) = \|b - A(x_0 + V_m y)\|_2 = \|\beta e_1 - \bar{H} y\|_2.$$

在 GMRES 中, 我们求解:

$$\min_{x \in x_0 + K_m} \|b - Ax\|_2 \Leftrightarrow \min_{y \in \mathbb{R}^m} J(y) = \|b - A(x_0 + V_m y)\|_2 = \|\beta e_1 - \bar{H} y\|_2$$

子空间上の大規模問題 $\Rightarrow (m+1) \times m$ 的矩阵从最小余量问题.

GMRES 算法, 重启 GMRES 算法.

四. 改进的 GMRES.

2. 多重网格.

1. 特征问题和光滑子

2. Two-Grid cycles

3. 区域分解方法

1. 直接法和 Schur 补

1.1 块高斯消去法

1.2 Schur 补

2. 迭代分解法

第二章 最小二乘问题的数值解法

§1. 最小二乘解的数学性质

最小二乘解的特性：

设 $A \in \mathbb{R}^{m \times n}$, $m > n$, $b \in \mathbb{R}^m$, 最小二乘问题定义为：

$$\|Ax - b\|_2 = \min \|Ax - b\|_2. \quad \dots (1)$$

该问题 (1) 的解集为： $\mathcal{X}_{LS} = \left\{ x \in \mathbb{R}^n \mid x \text{ 满足 (1)} \right\}$

定义最小范数解为： $x_{LS} = \underset{x \in \mathcal{X}_{LS}}{\operatorname{argmin}} \|x\|_2$

定理 1.1. $x \in \mathcal{X}_{LS} \Leftrightarrow A^T(Ax - b) = 0$.

结论 1.1. (1) \mathcal{X}_{LS} 是凸集

(2) \mathcal{X}_{LS} 是闭集

(3) $\mathcal{X}_{LS} = \{x_{LS}\}$ 充分必要条件是 $\operatorname{rank}(A) = n$.

1.2. $\xrightarrow{\text{解}} \text{最小二乘解的} - \text{正交表示}$

定义: Moore-Penrose 逆，记作 A^+ , 若 $A \in \mathbb{R}^{m \times n}$, $A^+ \in \mathbb{R}^{n \times m}$

$$(1) A A^+ A = A.$$

$$(2) A^+ A A^+ = A^+$$

$$(3) (A A^+)^T = A A^+$$

$$(4) (A^+ A)^T = A^+ A.$$

$$\text{注: } (1) P_{R(A)} = A A^+, \quad P_{N(A^+)} = I - A A^+$$

$$P_{R(A^+)} = A^+ A, \quad P_{N(A)} = I - A^+ A.$$

定理 2.1. LS 问题的解由 $x = A^+ b + (I - A^+ A)z$ 给出.
其中 $z \in \mathbb{R}^n$ 为任意向量. $x_{LS} = A^+ b$.

1.3. $\xrightarrow{\text{解}} \text{最小二乘解的扰动分析.}$

假定 $A, \delta A \in \mathbb{R}^{m \times n}$, $b, \delta b \in \mathbb{R}^m$. 设 $x = \arg \min_{v \in \mathbb{R}^n} \|Av - b\|_2$,

$x + \delta x = \arg \min_{v \in \mathbb{R}^n} \|(A + \delta A)v - (b + \delta b)\|_2$.

$\Rightarrow x = A^+ b, \quad x + \delta x = (A + \delta A)^+ (b + \delta b)$.

定理 1.3. 如果 $\text{rank}(\tilde{A}) = \text{rank}(A)$, 且 $\eta < 1$, 则:

$$\|\delta x\|_2 \leq \frac{K}{1-\eta} \left(\sum_A \|x\|_2 + \frac{\|\delta b\|_2}{\|A\|_2} + \sum_B K \frac{\|r\|_2}{\|A\|_2} \right) + \sum_A K \|x\|_2.$$

其中 $r = b - Ax$.

§2. 求解满秩 LS 问题的直接方法.

$A \in \mathbb{R}^{m \times n}$, $\text{rank}(A) = n$, \mathcal{X}_{LS} 中只一个元素 x_{LS} .

2.1 不规则方法.

由定理 1.1. $x \in \mathcal{X}_{LS} \Leftrightarrow A^T A x = A^T b$, $\because \text{rank } A = n$.

$\therefore A^T A x = A^T b$ 有唯一解, 由于 $A^T A$ 为对称, \therefore 用 Cholesky 分解法求解.

2.2 乙方法

$$\because \|Ax - b\|_2 = \min_{v \in \mathbb{R}^n} \|Av - b\|_2 = \min_{v \in \mathbb{R}^n} \|Q^T(Av - b)\|_2,$$

其中 Q 为 $m \times m$ 阶正交矩阵.

因此, 可选择合适的 Q , 将问题转化为容易求解的 LS 问题.

设 A 有 QR 分解: $A = Q \begin{bmatrix} R \\ 0 \end{bmatrix} = Q, R$, 其中 $Q \in \mathbb{R}^{m \times m}$ 是正交矩阵.

$Q = [Q_1, Q_2]$, $R \in \mathbb{R}^{n \times n}$ 是对角成为乙形的上三角矩阵.

$$\text{记 } d = Q^T b = \begin{bmatrix} Q_1^T \\ Q_2^T \end{bmatrix} b = \begin{bmatrix} d_1 \\ d_2 \end{bmatrix}_{m-n}^T.$$

$$\text{则有 } \|Q^T(Ax - b)\|_2^2 = \left\| \begin{bmatrix} R \\ 0 \end{bmatrix} x - \begin{bmatrix} d_1 \\ d_2 \end{bmatrix} \right\|_2^2 = \|Rx - d_1\|_2^2 + \|d_2\|_2^2.$$

$$\therefore x \in \partial \mathcal{E}_{LS} \Leftrightarrow Rx = d_1.$$

乙方法的步骤如下:

(1) 求乙矩阵 A 的 QR 分解. $A = Q, R$

(2) 计算 $d_1 = Q_1^T b$,

(3) 解线性方程 $Rx = d_1$

QR 分解的方法: (1) Householder 方法

(2) Givens 方法

(3) 改进的 Gram-Schmidt 乙方法.

§3. 求解和求 LS 问题的直接法

$\text{rank}(A) = n$, $\partial \mathcal{E}_{LS}$ 中有无穷多个解.

3.1 3n 之元 QR 分解法

思路: 对 A 进行行约化, 使得其前 r 行线性无关, 然后 QR 分解.

即: $A P = Q \begin{bmatrix} R_{11} & R_{12} \\ 0 & 0 \\ \vdots & \vdots \\ 0 & 0 \end{bmatrix}_{m-r}^r$, 其中 P 是排列矩阵, Q 是正交矩阵, R_{11} 是上三角矩阵.

2.1 Q 和 M 分别表示 R(A) 的一个矩阵和一个向量.

3.2 奇异值分解法

$$A = U \Sigma V^T, \quad \Sigma = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}_{r \times r}, \quad \Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$$

$$\sigma_1 \geq \dots \geq \sigma_r > 0.$$

$$2.2 x_{LS} = A^+ b = V \begin{bmatrix} \sigma_1^{-1} & & \\ & \ddots & \\ & & 0 \end{bmatrix}_{r \times r} U^T b = \sum_{i=1}^r \frac{U_i^T b}{\sigma_i} v_i$$

3.3 特征值问题和特征方法

定义 3.1. 设 $A \in \mathbb{R}^{n \times n}$, 如果对某一正数 δ 有:

$$r = \min \{ \text{rank}(B) : B \in \mathbb{R}^{n \times n}, \|B - A\|_2 \leq \delta \}.$$

则称 r 是矩阵 A 的特征值.

第七章. 求解特征值问题的 QR 方法

§1. 特征值和特征向量的计算.

1.1. 特征值的条件数.

Weierstrass-Hoffmann 定理, 若 B 是两个 $n \times n$ 阶正规矩阵,

$$\left(\sum_{i=1}^n |\lambda_{\pi(i)} - \lambda_i|^2 \right)^{\frac{1}{2}} \leq \|B - A\|_F.$$

定理: A 的特征值条件数:

$$\nu(A) = \inf_{Q \in \mathcal{D}_A} \|Q\|_2 \cdot \|Q^{-1} A Q\|_2$$

$$\text{其中 } \mathcal{D}_A = \{ Q \in \mathbb{C}^{n \times n} : Q^{-1} A Q = J \}$$

证明: ① 若 A 是正规矩阵, $\nu(A) = 1$

② $\nu(A)$ 是 A 对全部特征值的条件数.

§1.2 不变子空间和条件数.

定义：矩阵 $B \in \mathbb{C}^{l \times l}$ 与 $C \in \mathbb{C}^{m \times m}$ 的分离度为：

$$\text{sep}(B, C) = \inf_{\substack{P \in \mathbb{C}^{m \times l} \\ \|P\|_2 = 1}} \|PB - CP\|_2.$$

性质：① $\nexists \lambda(B) \cap \lambda(C) = \emptyset$ 时, $\text{sep}(B, C) > 0$.

$$\text{② } \text{sep}(B, C) \leq \min \{ |\lambda - \mu|, \lambda \in \lambda(B), \mu \in \lambda(C) \}$$

定义：不变子空间 $R(\mathbf{x})$ 的条件数： $\text{sep}(A_{11}, A_{22})$.

§2. 两步位移的 QR 算法

2.1. QR 算法基本思想.

2.2. 完 Schur 木块形

2.3. 上 Hessenberg 木块

2.4. 两步位移的 QR 迭代

§3. 特征向量和不变子空间

3.1. 特征向量计算

第八章. 漱近似方法

一. 单向量迭代

1.1. 乘幂法

1.2. 反幂法

二. 改进技术

2.1. Wielant Deflation

2.2. 2-投影法

1-2-投影法

2. Hermite 矩阵

第九章 子空间迭代

一、简单子空间迭代

二、投影子空间迭代

三、Arnoldi 方法

四、Lanczos 方法

五、块子空间方法

六、Lanczos 过程收敛性

1. 特征向量与 Km 的距离

2. 特征值收敛性

3. 特征向量

4. Arnoldi 过程的收敛性